

與 Claude 討論期末計畫：對話過程與結論

課程：電腦硬體與程式語言在行為科學實驗與大數據分析之應用 姓名：Irene Ho (中央大學認知神經科學研究所) 主題：以臺北捷運開放資料製作 Streamlit 互動分析網站 日期：2026-05-24

一、向 Claude 描述我的期末計畫與擬進行的分析

我計畫使用兩份臺灣政府開放資料 (data.gov.tw · 臺北大眾捷運公司)，製作一個公開的 Streamlit 互動網站。

資料來源 (經 Claude 協助驗證後確認)

檔案	粒度	主要欄位
臺北市捷運客運概況按月別.csv	月 × 全系統 (1998-01 ~ 2026-03 · 連續無缺)	客運人次 (總/中運量/高運量)、平均每日客運人次、客運收入 (總/中/高)
臺北市捷運各站進出站人次 (年別)	年 × 站 (1996 ~ 2025 · 30 年、134 站)	進站人次、出站人次、進/出站增減率%

討論中釐清的重點：兩份檔其實是**同一個系統 (臺北捷運)**，「客運」指載客而非公路客運；兩檔年度總量對得起來 ($\approx 97\%$)。「中運量」=文湖線、「高運量」=其餘重運量路線。

我原本擬進行的四項分析與 Streamlit 展示

- 歷史人次 & 營收的變化趨勢 (折線圖)
- 高運量 vs 中運量的貢獻比例 (堆疊長條圖)
- 以月為單位分析淡季與旺季、以年為單位看是否有運量崩跌時期 (如疫情)
- 捷運站點人流排行

過程中也評估過第三份資料「每日分時各站 OD 流量」，但單月即達約 280 MB、全量約 30 GB，遠超 GitHub / Streamlit Cloud 限制，討論後決定不採用，維持上述兩份檔。

二、Claude 列舉的三個我構想以外的可能性

Claude 在提出時，先用實際資料跑數字驗證可行性，再說明價值：

1. 每人平均票價 (客單價) 趨勢

- 做法：以「收入 ÷ 人次」算出平均票價，看其隨時間變化，並比較中/高運量單價差。
- 驗證：2025 全系統客單價 24.23 元；文湖線（中運量）27.18 元 高於高運量 23.92 元，因此文湖線「人次佔 9.5%、收入卻佔 10.6%」。
- 價值：派生指標，能講出票價政策（如 TPASS 月票）對營收的影響。

2. 站點通勤潮汐：進站 vs 出站不平衡（住宅型 vs 商業型站）

- 做法：以「進站 ÷ 出站」比值，將站分為淨流出（住宅型）與淨流入（商業 / 轉乘型）。
- 驗證：松江南京（綠線端）進出比 1.53 偏住宅向；忠孝復興 0.82 偏商業向，符合直覺。
- 價值：把「人多 / 人少」升級為「人流性質」，是空間維度的洞見。

3. 運量集中度（Pareto / 洛倫茲曲線）

- 做法：回答「少數大站撐起多少比例」，並可加 Gini 係數量化不均。
- 驗證：全系統 132 站中，前 30 站即佔 50% 進站量、前 10 站佔 23.4%，高度集中。
- 價值：與我原本的「排行榜」互補——排行看「誰最高」，集中度看「整體有多不均」。

三、我挑選的構想與 Claude 的規劃

我挑選：構想 2「站點通勤潮汐：進站 vs 出站不平衡」

理由：把單純的人流量轉化為「站點功能屬性」，且只用現有資料、零額外成本。

Claude 為此構想規劃的模組（整合進整體 app 架構，編為 M5）

- 資料：各站進出站（年）
- 指標： $\text{進站人次} \div \text{出站人次}$ → 比值 >1 偏住宅型（居民早上進站通勤）、 <1 偏商業 / 轉乘型
- 圖表：散點圖（ $x = \text{進站量}$ 、 $y = \text{進出比}$ ），依分群上色
- 互動 widget：年份選擇、合併同站閘門 toggle、最少人次門檻（過濾小站雜訊）
- 資料陷阱處理：轉乘站會依路線閘門被拆成多筆（如「頭前庄」與「頭前庄Y」），導致比值失真 → 提供「站名合併」或「只看單線站」選項
- AI 加值：分頁內「AI 解讀目前畫面」按鈕，將篩選後摘要送 claude-sonnet-4-6，回傳對住宅 / 商業型分布成因的繁中解讀

此模組與我原本四項共同構成五個分析分頁，並對應期末評分要求（ ≥ 2 互動 widget、Plotly 圖含標籤單位標註、Claude AI 功能、pytest + GitHub Actions、Streamlit Cloud 公開部署）。

四、我的評論：原始規劃 vs Claude 的建議（自己的話）

我原本的四項規劃方向——人次與營收趨勢、運量結構、淡旺季與疫情衝擊、站點排行——這些是捷運運量分析都會看的基本資訊。但和 Claude 討論後，我發現自己原始規劃的問題比較在於「停在描述層次」：大多是「畫出某個量隨時間或站別怎麼變」，少了「為什麼」與「結構性」的提問。

Claude 的三個建議剛好補上這個缺口。而這些建議不是憑空發想，而是先用真實資料跑出數字佐證才提出——例如先算出文湖線單價較高、前 30 站佔一半運量，這讓建議很有說服力，也讓我確認資料真的撐得起這些分析。我最後選的「通勤潮汐」就是一個我原本完全沒想到的角度：同樣是進出站人次，我只想到拿來「排名」，Claude 卻看出可以用「進出比」反映站點的功能屬性，把交通資料連結到空間行為，這對我很有啟發。

另一個我覺得 Claude 可以幫助我的是它對資料品質陷阱的敏感度。我原本不會注意到：(1)「中運量 vs 高運量」是車種之分而非人多人少；(2) 台北車站被拆成 R、BL 兩個閘門，不合併會讓它「消失」在榜首、反而西門假性奪冠；(3) 2026 只有三個月，直接算年會出現假性 -75% 崩跌；(4) 2 月運量低有部分只是天數少，應改用「平均每日」才公平。這些都是會讓分析「看起來對」的細節，是我自己做很可能會踩到的坑。

當然，Claude 的建議也不是全盤照收。OD 流量那份資料雖然最豐富，但我評估過後因檔案過大、徒增複雜度而主動放棄——這提醒我，AI 會把所有可能性攤開，但取舍仍需由我依目標與成本判斷。

結論：我的原始規劃提供了基本的分析骨幹，Claude 的建議則在「深度」（派生指標、結構性問題）與「嚴謹度」（資料陷阱）兩方面把它升級。最終我採「原始四項 + 通勤潮汐」共五個模組，並納入所有資料處理上的精進點。

附錄：討論中釐清的關鍵資料事實

項目	結論
捷運 vs 客運	同一系統；「客運」=載客，年總量對得起來 ≈97%
OD 資料	單月 ~280 MB、全量 ~30 GB，過大故不採用
中 / 高運量	車種之分：中運量=文湖線（~9.5%）、高運量=其餘
台北車站	R+BL 合併 5,545 萬 > 西門 2,489 萬（排行須合併閘門）
2026 年	僅 1–3 月，年分析須排除以免假性崩跌
崩跌年	SARS 2003（-2.5%）、COVID 2020（-11.9%）、2021（-23.7%）